

■ 2026 인하 인공지능 챌린지

로봇 미래 행동 영상 생성: 월드 모델 챌린지

팀 최후의 18시간

강지혜, 김건우, 이상혁

목차

01

문제 정의

이미지와 행동으로 미래 영상 예측

02

평가 분석

정지된 영상이 기준 모델보다 좋은 이유

03

접근 전략

외관 보존과 행동 정합

04

구현 방법

LoRA 학습과 행동 기반 후처리

05

실험 결과


생성 영상 비교와 최종 성적

06

한계와 향후 과제

남은 문제와 개선 방향

현재 이미지와 주어진 행동으로 미래 영상을 예측



핵심 목표 – 주어진 행동에 따라 로봇과 주변 장면이 어떻게 변할지 예측합니다.

무엇을 기준으로 평가하는가?

$$\text{Score} = 0.3 \times \text{DINO} + 0.3 \times \text{Video(R3D)} + 0.4 \times \text{Action MAE}$$

외관 유사도 30%

각 프레임이 정답 영상과 얼마나 비슷한가?

DINOv2 프레임 특징과 코사인 거리

영상 유사도 30%

움직임과 시간 흐름이 정답 영상과 얼마나 비슷한가?

R3D-18 시공간 특징과 코사인 거리

행동 정합성 40%

영상 속 로봇이 주어진 행동을 얼마나 잘 따르는가?

생성 영상에서 역추정한 행동 vs 조건 행동 L1

핵심 목표 – 세 지표를 가중합하며, 최종 점수는 낮을수록 좋습니다.

핵심 관찰과 설계전략

제출	LB Score	Action	DINO+Video
공식 Baseline (diffusion)	0.51708	0.5792	0.951 - 외관 붕괴
정지영상 (첫 프레임 반복)	0.30321	0.4287	0.439 - 외관 보존

외관 보존

움직임 영역 밖의 배경을 첫 이미지로 복원.


사전학습 활용

백본을 고정, LoRA와 행동 임베더를 학습

행동 정합성 강화

자체 행동 판독기로 입력 행동과의 차이를 줄이도록 학습

NVIDIA Cosmos-Predict2.5-2B (action-conditioned)



Cosmos-Predict2.5 공식 아키텍처 (NVIDIA 테크리포트)

선정 근거


- 이미지 1장 + 행동 시퀀스 → 미래 프레임: 태스크 입출력이 대회와 일치
- 2B - 단일 96GB, 4일, 1시간 제약에 적합
- robot action-cond 공개 체크포인트 + NVIDIA Open Model License

대회 데이터에 맞춘 학습

공개 모델은 행동을 4프레임 청크로 timestep/AdaLN 경로에만 주입

LoRA, Action Encoder를 학습해 로봇 영상과 행동의 대응을 조정

기존 행동 조건 구조와 LoRA 학습




유지하는 부분

- 기존 행동 입력 경로와 사전학습 백본의 기본 가중치
- 백본 기본 가중치는 고정

학습하는 부분


- Attention/MLP의 LoRA r32와 행동 임베더
- 학습 파라미터 약 113.4M

단계적 학습 전략과 가중치 평균 (Model Soup)




IDM 기반 행동 정합성 학습

Inverse Dynamics Model 사전 학습



IDM-based Action Consistency Loss



- Stage 2의 약 30% step에서 적용
- 전체 손실 = Flow Matching Loss + 0.3 X Action L1 Loss

고정 추론 설정과 선택적 배경 복원

216개 평가 샘플 전체에 동일한 고정 추론 설정 사용 – Sampling steps 30, seed 7, Auto-guidance 0.6



- 움직임 영역 마스크: 생성 영상과 첫 이미지의 픽셀 차이로 계산
- 임계값 선정: 제출 결과 비교로 45도를 선택했으며, 검증셋 기반 선정은 향후 과제

리더보드 결과

구성	Public	Private	비고
공식 Baseline	0.51708	-	-
정지 영상 (하한 선)	0.30321	-	-
Cosmos + LoRA (Stage 1)	0.22053	-	-
최종: Stage 2 + Soup + 배경 앵커	0.17533	0.19226	Private 2위

최종 순위	구분	학부생 트랙	대학원생 트랙	비고
1위	대상	공공공	mainunit	총장상
2위	최우수상	닉네임20자이하로지으라는데뭐라써야하지	최후의 18시간	센터장상, BK연구단장상, 로봇단장상
3위	우수상	제발	내친구로봇	
4위		안녕하세요홍태양임윤택입니다반갑습니	금리 인하 챌린지	
5위		JinM_KIM	인공지능융합	

최종 성적

대학원생 트랙 2위

최우수상

정성 평가 - 생성 영상



한계와 향후 개선 방향


현재 한계

- 후처리 기준의 일반화 – 45도 임계값을 제출 결과 비교로 선정
- 시각적 품질과 구조적 일관성 – 영상 뭉개짐과 아티팩트 발생, 물체 형태/로봇 관절 구조가 프레임 사이에서 불안정
- 고정된 추론 방식 – 30단계 샘플링으로 단일 후보 생성

향후 개선 방향

- 검증셋 기반 기준 선정 – 별도 검증셋에서 임계값과 적용 효과 검증
- 물체/관절 중심의 품질 개선 – 영역별 오류를 분석하고 형태 보존과 시간적 일관성을 강화하는 학습 검토
- 추론 효율 개선 – 단계 축소/증류와 복수 후보 선택을 실험
- 모델 용량 및 구조 개선 – 더 큰 백본의 효과를 검증하고, 물체 형태와 로봇 관절의 시간적 일관성을 강화하도록 모델 구조 개선

팀 최후의 18시간



강지혜

전기컴퓨터공학과

INHA GCL LAB / MS



김건우

인공지능공학과

KAIST AI DAVIAN Lab / Intern



이상혁

전기전자공학부

UNIST MI Lab / Intern

■ 감사합니다